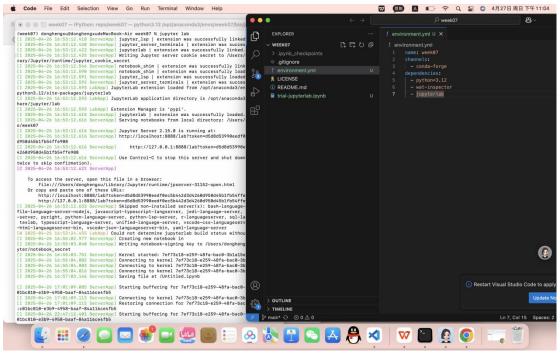
## 第七周报告

用 VS Code 打开项目目录,新建一个 environment.yml 文件,指定安装 Python 3.12 和 jupyterlab,然后运行 conda env create 命令创建 Conda 环境

在项目目录下,运行 jupyter lab 命令,启动 后端 (Backend) 服务,在浏览器里粘贴地址 访问 前端 (Frontend) 页面



在单元格 (Cell) 里编写 Python 代码, 按 Shift+Enter 运行 Cell 并下移 在单元格 (Cell) 上按 ESC 切换到 命令模式 (command mode), 按 Enter 切换到 编写模式 (edit mode)

在单元格 (Cell) 的命令模式下,按j选择下一个,按k选择上一个,按a在上方添加,按b在下方添加,按dd删除,按住Shift多选,按x剪切,按c复制,按v粘贴,按Shift+M合并,按z撤销,按Shift+Z重做,按Shift+L显示/隐藏代码行号

```
In [2]: import time
38/ In [3]: while True:
             print('hello')
                time.sleep(3)
   hello
el le
  hello
   hello
   hello
   KeyboardInterrupt
                                               Traceback (most recent call last)
   Cell In[3], line 3
         1 while True:
         2
                print('hello')
lifie
       -> 3
                time.sleep(3)
ag
    KeyboardInterrupt:
erda
erda In [4]:
```

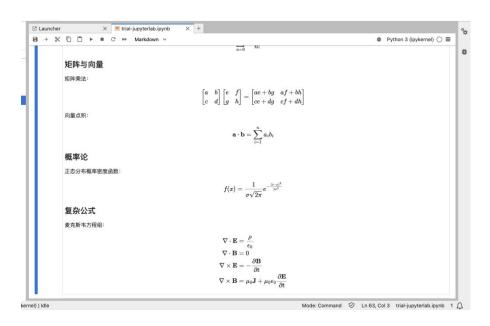
用豆包 (或 DeepSeek 等任何大模型) 生成一段示例 Markdown 代码, 复制粘贴进 Markdown 单元格, 运行以呈现 (Render)



用豆包 (或 DeepSeek 等任何大模型) 生成一段示例 HTML 代码,复制粘贴进 Markdown 单元格,运行以呈现 (Render); 注意不支持 CSS



用豆包 (或 DeepSeek 等任何大模型) 生成一段示例 LaTeX 数学公式代码,复制粘贴进 Markdown 单元格,运行以呈现 (Render);注意要用 \$ (行内模式) 或 \$\$ (整行模式) 包围



## 关闭前端页面, 在后端按 Ctrl+C 打断运行中的服务, 回到 Bash 提示符

```
week07 - -zsh - 94×32
     2025-05-07 09:35:39.118 ServerApp] Restoring connection for ff6735d4-0cc6-4253-bbb1-20d952e
  b8fdb:1a558483-98c8-4878-8fa7-f163cd0e2440
                                              erApp] Starting buffering for ff6735d4-0cc6-4253-bbb1-20d952eb8
  fdb:1a558483-98c8-4878-8fa7-f163cd0e2440
  [I 2025-05-09 14:59:17.329 ServerApp] Connecting to kernel ff6735d4-0cc6-4253-bbb1-20d952eb8fd
  [I 2025-05-09 14:59:17.330 ServerApp] Restoring connection for ff6735d4-0cc6-4253-bbb1-20d952e
  b8fdb:1a558483-98c8-4878-8fa7-f163cd0e2440
   I 2025-05-09 16:02:50.558 ServerApp] Saving file at /trial-jupyterlab.ipynb
I 2025-05-09 16:04:50.618 ServerApp] Saving file at /trial-jupyterlab.ipynb
  [I 2025-05-09 16:06:50.653 ServerApp] Saving file at /trial-jupyterlab.ipynb
[I 2025-05-09 16:08:50.688 ServerApp] Saving file at /trial-jupyterlab.ipynb
  [I 2025-05-09 16:12:50.722 ServerApp] Saving file at /trial-jupyterlab.ipynb
[I 2025-05-09 16:14:50.810 ServerApp] Saving file at /trial-jupyterlab.ipynb
  [I 2025-05-09 16:16:50.834 ServerApp] Saving file at /trial-jupyterlab.ipynb
[I 2025-05-09 16:18:50.865 ServerApp] Saving file at /trial-jupyterlab.ipynb
     2025-05-09 16:21:05.773 ServerApp] Starting buffering for ff6735d4-0cc6-4253-bbb1-20d952eb8
fdb:1a558483-98c8-4878-8fa7-f163cd0e2440
     [I 2025-05-09 16:21:47.267 ServerApp] interrupted
2025-05-09 16:21:47.268 ServerApp] Serving notebooks from local directory: /Users/donghengx
 u/repo/week07
       1 active kernel
       Jupyter Server 2.15.0 is running at: http://localhost:8888/lab?token=0c25e21969f69dd68b5e28be84e5ac83fa859d3d64eca7c6
            http://127.0.0.1:8888/lab?token=0c25e21969f69dd68b5e28be84e5ac83fa859d3d64eca7c6
 Shut down this Jupyter server (y/[n])? y
[C 2025-05-09 16:21:49.696 ServerApp] Shutdown confirmed
[I 2025-05-09 16:21:49.701 ServerApp] Shutting down 4 extensions
     2025-05-09 16:21:49.702 ServerApp] Shutting down 1 kernel
2025-05-09 16:21:49.703 ServerApp] Kernel shutdown: ff6735d4-0cc6-4253-bbb1-20d952eb8fdb
(week07) donghengxu@donghengxudeMacBook-Air week07 %
```

修改 environment.yml 文件, 添加 pip: tushare (注意, conda-forge 没有收录 tushare, 只能从 PyPl 安装, 参考) 依赖项, 运行 conda env update 更新 Conda 环境

运行 set\_token 函数会把 Token 字符串保存在 ~/tk.csv 文件里, 今后每次使用 tushare 软件包请求数据时都会自动读取并发送 Token, 不需要反复设置。

```
Last login: Sun Apr 27 23:20:34 on ttys007
(base) donghengxu@donghengxudeMacBook-Air ~ % ls
Applications
                                Pictures
Applications (Parallels)
Desktop
                                Visual Studio Code.app
Documents
                                Visual Studio Code的副本.app
Downloads
                                abc.txt
Library
                                brew-install
Movies
                                repo
                                report.txt
Music
Parallels
                                tk.csv
(base) donghengxu@donghengxudeMacBook-Air ~ % cat ts.csv
cat: ts.csv: No such file or directory
(base) donghengxu@donghengxudeMacBook-Air ~ % cat tk.csv
my fake token
(base) donghengxu@donghengxudeMacBook-Air ~ % ■
```

```
[In [1]: import tushare as ts
 [In [2]: pro = ts.pro_api()
[In [3]: df = pro.new_share()
*[In [4]: df
 Out[4]:
         ts_code sub_code name ipo_date
                                                   pe limit_amount
                                                                     funds ballot
                                     20250519 ... 0.00
20250508 ... 24.82
       001390.SZ
                   001390
                          古麒绒材
                                                                  2.00
                           威高血净太力科技
       603014.SH
                   732014
                                                                  1.10
                                                                        10.902
                                                                                  0.03
       301595.SZ
                   301595
                                     20250508
                                                    21.55
                                                                   0.65
                                                                         4.615
                                                                                  0.02
                                              . . .
       688755.SH
                   787755
                           汉邦科技
                                     20250507
h 4
       301636.SZ
                   301636
                           泽润新能
                                     20250428
                                               ... 17.57
                                                                  0.45
                                                                         5.279
                                                                                  0.02
1995
      300776.SZ
                   300776
                           帝尔激光
                                     20190507 ...
                                                    22.99
                                                                  1.60
                                                                         9.543
                                                                                  0.01
 1996
       300777.SZ
                   300777
                           中简科技
                                     20190506
                                              ...
                                                    22.98
                                                                  1.10
                                                                         2.425
                                                                                  9.94
 1997
       603267.SH
                   732267
                           鸿远电子
                                     20190430
                                              ... 16.50
                                                                  1.60
                                                                         8.367
                                                                                  0.03
 1998
       600989.SH
                   730989
                           宝丰能源
                                     20190430
                                                    22.07
                                                                 22.00
                                                                        81.550
                                                                                  0.25
                                              ...
 1999
       300778.SZ
                   300778
                            新城市
                                   20190425 ... 22.99
                                                                 2.00
                                                                        5.466
                                                                                 0.02
 [2000 rows x 12 columns]
 [In [5]: df.to_parquet("new_share.parquet")
 In [6]:
```

```
In [7]: df = pro.stock_basic()
In [8]: df.to_parquet("stock_basic.parquet")
pe')
In [10]: df
Out[10]:
                               name area ... delist_date is_hs
平安银行 深圳 ... None
万科A 深圳 ... None
*ST国华 深圳 ... None
深振业A 深圳 ... None
       ts_code symbol
000001.SZ 000001
                                                                           act_name act_ent_type
       000002.SZ
000004.SZ
                   000002
000004
                                                                                                                                  地方国企
       000006.SZ
000007.SZ
                                                                                                                                    地方国企
                   000007
... 5407 920489.BJ 920489
5408 920682.BJ 920682
5409 920799.BJ 920799
5410 920819.BJ 920819
5411 689009.SH 689009
                             住先股份
球冠电软
類泰生物
九号公司-WD
                                                                None ...
In [11]: df.to_parquet("stock_basic.parquet2")
```

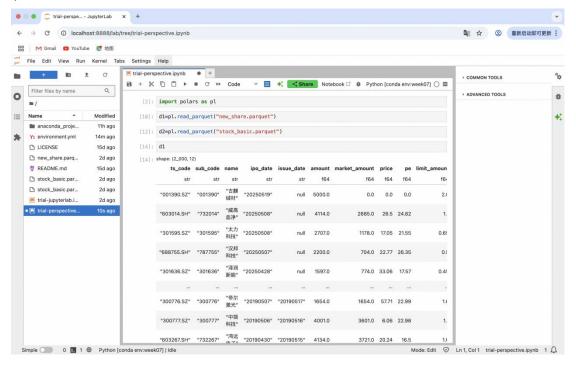
通过 perspective-python 软件包查看 polars.DataFrame 数据,实践交互式可视化 首先在 VScode 内在 environment.yml 文件夹中添加 perspective-python 和 polars 依赖项,运行 conda env update 更新 Conda 环境。

启

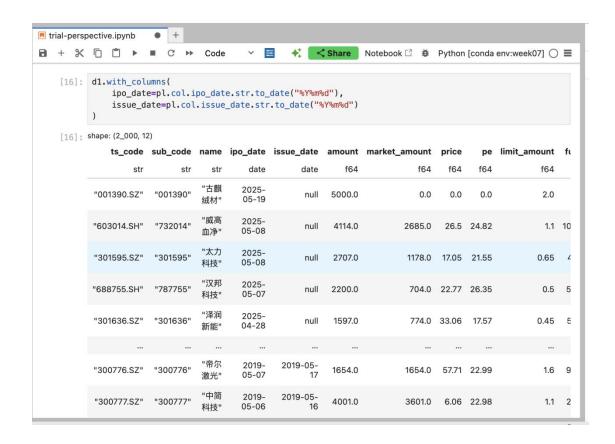
动 JupyterLab,新建一个 Notebook, 改名为 trial-perspective.ipynb



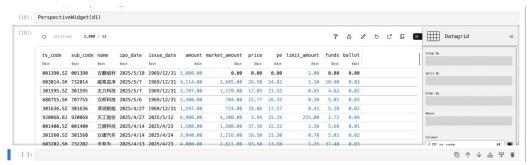
调用 polars.read\_parquet 函数,分别读取磁盘 (disk) 中的 new\_share.parquet 文件和 stock\_basic.parquet 文件,得到内存 (memory) 中的 polars.DataFrame 对象,命名为 d1 和 d2



进行适当的列变换,尤其是要把实际上是日期类型的列,从 polars.String() 类型转换为 polars.Date() 类型



把 d1 或 d2 作为参数传递给 perspective.widget.PerspectiveWidget 类型进行初始化, 返回的对象会呈现在 NoteBook 的 Output 里



在 PerspectiveWidget 默认的 Datagrid 视图下,尝试实践: 修改各种列数据类型 (文本、数值、日期) 的显示风格 (style)



设置 Group By 选项,选择某些列作为分组依据 (纵向排列),选择其他某些列进行汇总 (注意汇总方式有多种函数选项)

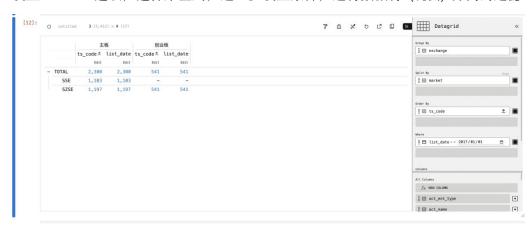
设置 Split By 选项,选择某些列作为拆分依据 (横向排列)



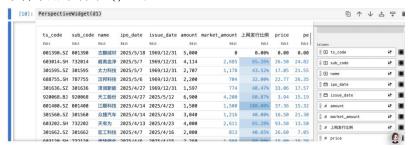
设置 Order By 选项,选择某些列作为排序依据 (注意可以切换 升序/降序)



设置 Where 选项,选择某些列,进一步设置条件,进行数据行(观测)方向的过滤



设置 Columns 选项,选择要显示的数据列 (变量),及其显示的先后顺序 在 All Columns 部分,是能够显示但没有显示的数据列 (变量),可以点击 NEW COLUMN 添加衍生计算出的新列,需要用 ExprTK 语言书写表达式代码,变量名用双引号 (")包围, 字符串用单引号 (")包围



在 PerspectiveWidget 图形界面依靠鼠标 (手动) 所做的设置 (configure),可以导出代码,根据导出的代码,可以修改我们的代码,使得我们运行代码直接就能得到我们所需要的视图 (自动化)

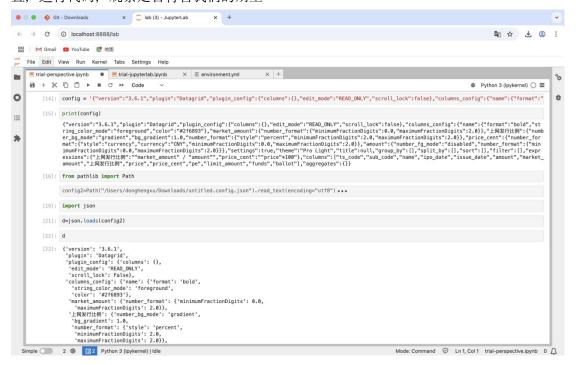
在 PerspectiveWidget 的右上方有按钮,可以把图形界面的数据或设置 (configure) 导出 (export) 为文件,或复制 (copy) 到剪贴板

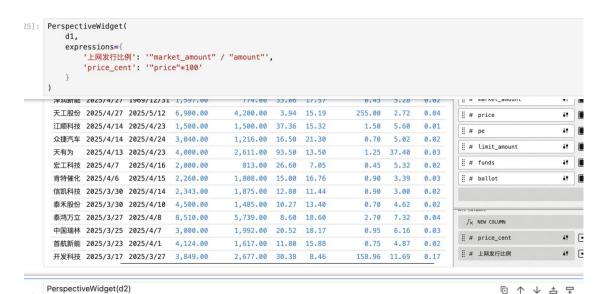
把设置 (config.json) 复制到剪贴板, 粘贴进 Notebook Cell, 保存成字符串 (str) 也可以把设置 (config.json) 导出为文件, 用 pathlib.Path.read\_text 方法从文件读取出字符串 (str)

可以用 json.loads 函数将无结构的 (unstructured) 字符串 (str) 解析为有结构的 (structured) Python 字典 (dict), 这样就容易在 Notebook 里美化呈现, 也容易进一步通过 Python 代码访问内部的具体设置

也可以把复制到剪贴板的 JSON 字符串, 粘贴进某个在线的 JSON 工具网站 (比如 链接) 进行美化

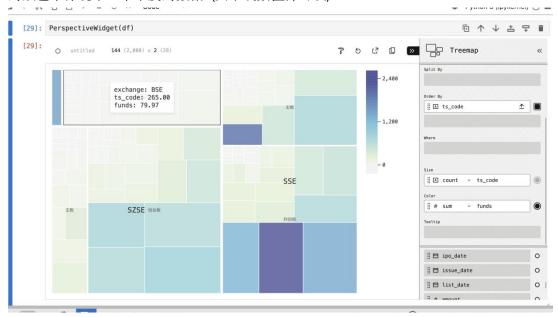
根据导出的设置代码,在初始化 (init) PerspectiveWidget 类型时,传入适当的参数进行设置,运行代码,观察是否符合我们的期望



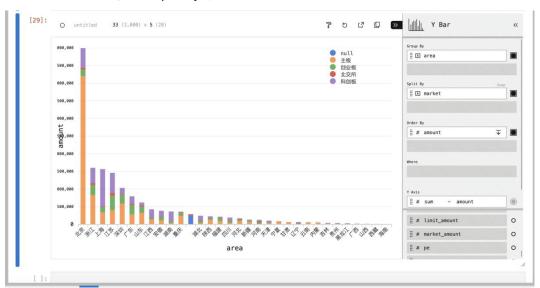


把 PerspectiveWidget 切换为 Treemap 视图, 尝试设置各种选项 (configure), 观察数据可视化的实际效果

Treemap (树形结构图) 用不同大小的矩形来体现数据的分类占比构成情况,还可以用矩形的颜色来体现第二个维度的数据 (文本或数值都可以)

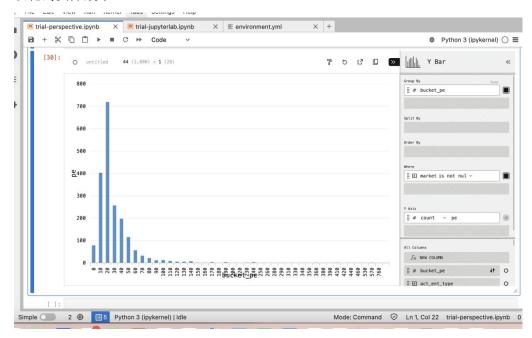


Y Bar (条形图/柱状图) 的横轴 (不同的条形) 是第一个维度,用 Group By 控制,纵轴 (条形的高度) 是第二个维度,用 Y Axis 控制 (支持多变量并列显示),还可以把每个条形进一步拆分为多个颜色,用 Split By 控制



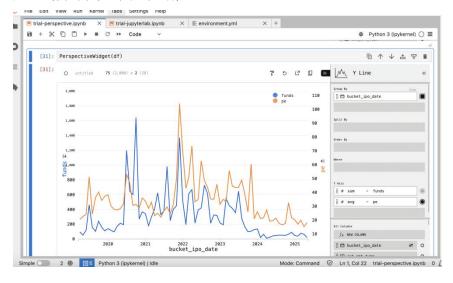
Y Bar 视图还可以用来实现一类很重要的统计制图 —— 直方图 (histogram)。对于数据表中的某一列连续型数值变量 (比如新股发行的市盈率 pe),我们经常希望观察其 分布 (distribution)。可以用 bucket 函数对连续变量进行 "分桶" (比如表达式 bucket("pe", 10)),生成一个新的离散变量 (比如命名为 bucket\_pe),然后把离散变量设置为 Y Bar 的横轴 (Group By),把任意其他一列变量用 count (计数) 函数汇总,设置为纵轴 (Y Axis)。这样看到的就是直方图。"分桶" 在有的地方也叫 "分箱" (bin),其粒度大小需要根据数据适当调节。把 PerspectiveWidget 切换为 Y Line 视图,尝试设置各种选项 (configure),观察数据可

## 视化的实际效果

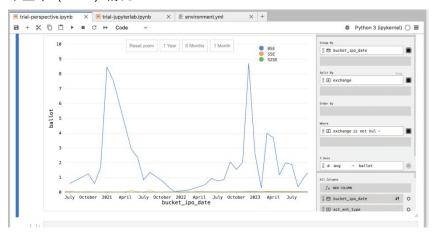


Y Line (折线图) 常用来绘制时间序列, 横轴通常是时间, 用 Group By 控制, 纵轴 (折线的 Y 坐标) 通常是连续型数值变量 (经过汇总), 用 Y Axis 控制 (支持多序列同时显示), 还可以进一步拆分为多条序列, 用 Split By 控制

使用我们的示例数据,可以尝试观察最近几年 A 股 IPO 市场的 融资额 (funds) 与 市盈率 (pe) 变化情况。为了加深对数据的 理解 和 验证,可以询问豆包 (或 DeepSeek 等任何大模型),在某个时间段内发生了哪些影响 A 股 (或 IPO) 的重大国内外财经事件,由此加强我们对现实背景的理解



也可以使用示例数据,观察对比最近几年不同交易所 (exchange) 或市场 (market) 的平均中签率 (ballot) 情况



把 PerspectiveWidget 切换为 X/Y Scatter 视图, 尝试设置各种选项 (cinfigure), 观察数据可视化的实际效果

X/Y Scatter (散点图) 常用来观察两个数值型连续变量之间的相关关系 (correlation)。数据首先可以进行分组汇总,每一个组对应一个散点,用 Group By 控制。然后把两个连续型数值变量分别设置为 X Axis 和 Y Axis, 其汇总数值将作为每个散点的坐标

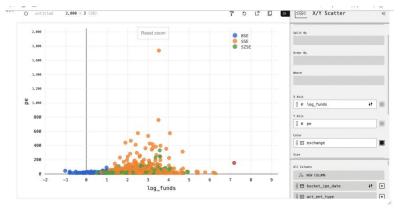
散点的分布如果特别不均匀,则意味着变量单位可能有问题,或者需要经过变换 (比如取对数)

散点的分布如果杂乱无规律,则意味着 X 与 Y 没有相关性

散点的分布如果看起来能够拟合成一条直线 (即回归线, regression), 则意味着 X 与 Y 具有正的或负的相关性, 意味着可能存在某些规律

散点图上可以进一步体现更多的变量维度,比如可以把更多变量映射为散点的不同颜色 (Color)、大小 (Size)、符号 (Symbol)、标签 (Label)、提示框 (Tooltip) 等

我们经常还可以把用于分类的类别变量 (类别不宜太多) 设置为 Split By, 从而把一个散点 图拆分为多个小散点图 (small multiple),从而更细致地观察是否存在规律



在我们的示例数据中,融资额 (funds)、市盈率 (pe)、中签率 (ballot) 是数值型连续变量,适合用散点图观察他们的规律,散点可以以个股为单位 (不汇总),也可以按行业 (industry) 汇总,或者按 上市时间 (ipo\_date) 汇总 (每月分桶),都可以大胆尝试

